

Semaine 2 Principal — PDFs · Chunking · Embeddings · Qdrant

2h/jour, code, projet RAG

Mardi 06/10/2026 → Lundi 12/10/2026

Semaine 2 — Bloc Principal

Thème : PDFs · Chunking · Embeddings · Qdrant

Période : Mardi 06/10/2026 → Lundi 12/10/2026

Rythme : 2h/jour, concentration, code.

Objectif de la semaine : Ton système ingère des PDFs, les chunk, les vectorise, les stocke dans Qdrant.

Jour 1 — Mar 06/10

Télécharger 20 PDFs open source

Créer data/pdfs/. Prendre 20 PDFs SNCF/Légifrance/rapports publics. Vérifier taille raisonnable (< 5Mo/pdf). **Livrable** : dossier avec 20 PDFs.

☐

Fait

☐

Testé

☐

Commité sur Git

Jour 2 — Mer 07/10

PyPDFLoader + extraction texte

`pip install pypdf langchain-community`. Script `load_pdfs.py` qui charge tous les PDFs et affiche le nombre de pages + un extrait. **Livrable** : script qui parse les 20 PDFs.

☐

Fait

☐

Testé

☐

Commité sur Git

Jour 3 — Jeu 08/10

RecursiveCharacterTextSplitter chunking

Ajouter chunking : RecursiveCharacterTextSplitter(chunk_size=500, chunk_overlap=50). Compter les chunks générés. Afficher un chunk exemple. **Livrable** : liste de N chunks affichée.

☐

Fait

☐

Testé

☐

Commité sur Git

Jour 4 — Ven 09/10

Embeddings Azure OpenAI text-embedding-3-small

pip install openai. Créer embed.py qui vectorise un chunk avec text-embedding-3-small (1536 dim). Vérifier que ça retourne un vecteur de 1536 floats. **Livrable** : embedding généré.

☐

Fait

☐

Testé

☐

Commité sur Git

Jour 5 — Sam 10/10

Docker Qdrant + client Python

docker run -p 6333:6333 -v qdrant_storage:/qdrant/storage qdrant/qdrant. pip install qdrant-client. Créer une collection docs avec 1536 dim, distance cosine. **Livrable** : collection Qdrant créée.

☐

Fait

☐

Testé

☐

Commité sur Git

Jour 6 — Dim 11/10

Upsert chunks + première recherche

Script `ingest.py` qui vectorise + upsert tous les chunks dans Qdrant. Puis `search.py` qui prend une question, la vectorise, et retourne les top 3 chunks. **Livrable** : recherche vectorielle qui marche.

☐

Fait

☐

Testé

☐

Commité sur Git

Jour 7 — Lun 12/10

Refacto `ingest.py` propre + tests

Réorganiser en modules : `loader.py`, `chunker.py`, `embedder.py`, `store.py`. Ajouter logs. Tester avec un PDF nouveau. **Livrable** : code propre + test manuel OK.

☐

Fait

☐

Testé

☐

Commité sur Git

Bilan Semaine 2

À remplir dans `journal.md` :

Ce que je sais faire techniquement

☐

(Compétence 1)

☐

(Compétence 2)

☐

(Compétence 3)

Bloquée / à revoir

(ce qui a coïncé)

Ma phrase pour l'entretien

(1-2 phrases qui résument ce que j'ai construit cette semaine)

Auto-évaluation

- Jours faits : ____ / 7
- Objectif principal atteint : OUI / NON
- Prêt pour semaine suivante : OUI / NON

Le board mural correspondant : boards/Board_Principal_S2.pdf